

PROPOSAL TUGAS AKHIR

**ANALISIS EVOLUSI TOPIK RISET SKRIPSI INFORMATIKA
MENGUNAKAN *NEURAL TOPIC MODELING* (BERTOPIC) BERBASIS
INDOBERT UNTUK *DYNAMIC TOPIC ANALYSIS*
SKRIPSI**

Disusun untuk memenuhi sebagian persyaratan untuk memperoleh gelar Sarjana
Komputer **Jurusan Informatika**



Disusun oleh:

Muhamad Galih

H1D022052

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS JENDERAL SOEDIRMAN
FAKULTAS TEKNIK
JURUSAN INFORMATIKA
PURWOKERTO
2025**

LEMBAR PENGESAHAN PROPOSAL

Tugas Akhir dengan judul:

**ANALISIS EVOLUSI TOPIK RISET SKRIPSI INFORMATIKA
MENGUNAKAN *NEURAL TOPIC MODELING* (BERTOPIC) BERBASIS
INDOBERT UNTUK *DYNAMIC TOPIC ANALYSIS***

Disusun oleh:

Muhamad Galih

Diajukan untuk memenuhi salah satu persyaratan memperoleh gelar

Sarjana Komputer pada Jurusan Informatika

Fakultas Teknik

Diterima dan disetujui

Pada tanggal

Pembimbing I

Pembimbing II

Dr. Ir. Nurul Hidayat, S.Pt. M.Kom.

NIP. 197305172003121001

Mohammad Irham Akbar, S.Kom., M.Cs.

NIP. 199408102022031010

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan proposal penelitian dengan judul "Analisis Evolusi Topik Riset Skripsi Informatika Menggunakan *Neural Topic Modeling* (Bertopic) Berbasis Indobert untuk *Dynamic Topic Analysis*." Proposal ini disusun sebagai salah satu syarat untuk menempuh Tugas Akhir pada Jurusan Informatika, Fakultas Teknik, Universitas Jenderal Soedirman.

Dalam penyusunan proposal ini, penulis mendapatkan berbagai dukungan, arahan, serta masukan dari banyak pihak. Oleh karena itu, dengan penuh hormat dan rasa syukur, penulis menyampaikan terima kasih kepada:

1. Bapak Prof. Dr. Eng. Ir. Agus Maryoto, ST., M.T., IPU., ASEAN Eng., selaku Dekan Fakultas Teknik, Universitas Jenderal Soedirman.
2. Bapak Dr. Ir. Lasmedi Afuan, S.T., M.Cs., IPM., selaku Ketua Jurusan Informatika, Fakultas Teknik, Universitas Jenderal Soedirman.
3. Bapak Dr. Ir. Nurul Hidayat, S.Pt., M.Kom., selaku Dosen Pembimbing I dan Bapak Mohammad Irham Akbar, S.Kom., M.Cs., selaku Dosen Pembimbing II yang dengan penuh perhatian telah memberikan bimbingan dan arahan selama penyusunan proposal ini.
4. Orang tua dan keluarga tercinta atas doa, semangat, serta dukungan yang tiada harganya.
5. Rekan-rekan seperjuangan di Jurusan Informatika angkatan 2022, serta seluruh pihak yang telah memberikan dukungan dan masukan.

Penulis menyadari proposal ini memiliki keterbatasan, sehingga kritik dan saran sangat diharapkan untuk perbaikan ke depan. Semoga karya ini dapat berkontribusi pada pengembangan ilmu, khususnya dalam bidang *Deep Learning* dalam Analisis Topik Dinamis (*Dynamic Topic Analysis*) yang memanfaatkan Pemodelan Topik Saraf (*Neural Topic Modeling*).

Purwokerto, 11 November 2025

Muhamad Galih

DAFTAR ISI

LEMBAR PENGESAHAN PROPOSAL	ii
KATA PENGANTAR.....	iii
DAFTAR ISI	iv
DAFTAR TABEL	vi
DAFTAR GAMBAR	vii
DAFTAR LAMPIRAN	viii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Batasan Masalah	3
1.4 Tujuan Penelitian	4
1.5 Manfaat Penelitian	5
BAB II TINJAUAN PUSTAKA	6
2.1 Skripsi	6
2.2 <i>Text Mining</i>	7
2.3 <i>Web Scraping</i>	7
2.4 <i>Natural Language Processing</i> (NLP)	8
2.5 <i>Text Preprocessing</i>	9
2.6 <i>Topic Modeling</i>	10
2.7 <i>Latent Dirichlet Allocation</i> (LDA)	10
2.8 Transformer.....	12
2.8.1 Encoder	14
2.8.2 Decoder	15
2.8.3 Multi-Head Attention	15
2.9 BERT.....	17
2.9.1 Representasi Input.....	17
2.9.2 Mekanisme Pra-Pelatihan (<i>Pre-training Objectives</i>).....	18
2.10 IndoBERT	19
2.10.1 Dataset Pra-Pelatihan (Indo4B)	20
2.10.2 Konfigurasi dan Performa <i>Benchmark</i> (IndoNLU)	21
2.11 BERTopic	22
2.11.1 <i>Document Embedding</i> (Sentence-BERT).....	23
2.11.2 <i>Dimensionality Reduction</i>	24

2.11.3 <i>Clustering</i>	25
2.11.4 <i>Class Based Term Frequency – Inverse Document Frequency (c-TF-IDF)</i>	26
2.11.5 <i>Maximal Marginal Relevance (MMR)</i>	27
2.12 <i>Dynamic Topic Modeling (DTM)</i>	29
2.13 Evaluasi Kinerja Model	30
2.13.1 <i>Topic Conherence</i>	30
2.13.2 <i>Topic Diveristy</i>	32
2.14 Penelitian Sejenis	32
BAB III METODOLOGI PENELITIAN	37
3.1 Waktu dan Tempat Penelitan.....	37
3.2 Alat Penelitian	37
3.3 Tahapan Penelitian	38
3.3.1 Pengumpulan Data (<i>Data Collection</i>).....	39
3.3.2 Arsitektur Pipeline Data (<i>Data Pipeline Architecture</i>)	40
3.3.3 Pra-pemrosesan Data (<i>Text Preprocessing</i>).....	42
3.3.4 Pembangunan Model Topik	42
3.3.5 Evaluasi dan Seleksi Model	43
3.3.6 Analisis Dinamika Topik (<i>Dynamic Topic Analysis</i>)	44
3.3.7 Visualisasi dan Interpretasi Hasil	44
3.4 Jadwal Penelitian	45
DAFTAR PUSTAKA.....	48

DAFTAR TABEL

Tabel 2. 1 Statistik Dataset Indo4B (Wilie dkk., 2020).....	20
Tabel 2. 2 Perbandingan Performa Model (Wilie dkk., 2020)	21
Tabel 2. 3 Perbandingan Penelitian Terkait	33
Tabel 3. 1 Jadwal Penelitian	46

DAFTAR GAMBAR

Gambar 2. 1 Representasi Model Grafis LDA (Blei dkk., 2003).....	11
Gambar 2.2 Model Arsitektur Transformer (Vaswani dkk., 2023)	14
Gambar 2. 3 Multi-Head Attention pada Transformer (Vaswani dkk., 2023).....	16
Gambar 2. 4 Representasi Input BERT (Devlin dkk., 2019)	17
Gambar 2. 5 Pre-Training & Fine-Tuning pada BERT (Devlin dkk., 2019)	18
Gambar 2. 6 Arsitektur dan Alur Kerja BERTopic (Grootendorst, 2022).....	22
Gambar 2. 7. Arsitektur Sentence-BERT pada saat inferensi (Reimers & Gurevych, 2019)	23
Gambar 3. 1 Diagram alur penelitian.....	39
Gambar 3. 2. Arsitektur Pipeline Data dan Pemrosesan Model.....	41

DAFTAR LAMPIRAN

BAB I

PENDAHULUAN

1.1 Latar Belakang

Domain Informatika di Indonesia mengalami akselerasi pesat, didorong oleh adopsi Kecerdasan Buatan atau Artificial Intelligence (AI) yang terus meningkat secara signifikan di berbagai sektor industri dan layanan publik. Pertumbuhan ini tidak hanya terlihat pada peningkatan efisiensi operasional perusahaan, tetapi juga tercermin dalam lanskap akademik. Analisis bibliometrik menunjukkan tren peningkatan yang konsisten dalam publikasi riset terkait AI di Indonesia, serta pembukaan program studi baru yang relevan dengan industri seperti AI dan *Data Science* (Natasya Priyani dkk., 2024). Ledakan adopsi dan riset AI ini secara langsung menciptakan permintaan eksponensial akan talenta digital. Namun, di sinilah letak tantangan kritis, terdapat bukti empiris adanya kesenjangan signifikan antara kurikulum perguruan tinggi yang "terlalu teoritis" dengan kebutuhan industri yang "dinamis" dan bergerak cepat (Fajari dkk., 2024).

Untuk menjembatani kesenjangan ini, repositori skripsi universitas berfungsi sebagai *corpus* data historis yang kaya untuk memetakan fokus penelitian mahasiswa dari tahun ke tahun (Rizki Yuni Lestari, 2025). Analisis terhadap data tekstual ini sangat penting untuk memberikan panduan strategis berbasis data bagi fakultas dalam evaluasi kurikulum. Namun, analisis manual tidak mungkin dilakukan, sehingga memerlukan teknik *Natural Language Processing* (NLP) seperti *Topic Modeling*. Sayangnya, metode konvensional seperti *Latent Dirichlet Allocation* (LDA) memiliki keterbatasan fundamental. LDA berbasis *bag-of-words*, yang membuatnya "mengabaikan urutan kata dan hubungan semantik yang lebih dalam" (Liu, 2024). Keterbatasan ini, ditambah dengan kesulitan subjektif dalam menentukan jumlah topik (K), membuat LDA tidak andal untuk analisis semantik dan pelacakan tren secara konsisten dari waktu ke waktu (Liu, 2024).

Celah metodologis ini mendorong transisi menuju *Neural Topic Modeling* (NTM), sebuah pendekatan yang memanfaatkan arsitektur *Deep Learning* (Transformer) untuk menghasilkan representasi kontekstual teks. Penelitian ini mengusulkan implementasi BERTopic, sebuah kerangka NTM

yang memanfaatkan *embeddings* berkualitas tinggi dari IndoBERT (model yang dioptimalkan untuk Bahasa Indonesia) dan menggabungkannya dengan teknik *clustering* (Ma dkk., 2025). Pilihan ini didukung oleh bukti empiris yang kuat, berbagai studi komparatif terbaru secara konsisten menunjukkan bahwa BERTopic mengungguli LDA dalam menghasilkan topik dengan skor koherensi (*coherence scores*) yang lebih tinggi (Cheddak dkk., 2024) serta kluster topik yang secara visual "lebih kompak dan terpisah dengan baik" (*more compact and well-separated*), membuktikan kemampuannya menghasilkan topik yang lebih bermakna dan mudah diinterpretasikan (Ma dkk., 2025).

Tinjauan terhadap penelitian sejenis di Indonesia menunjukkan dua keterbatasan utama. Pertama, penelitian yang menganalisis *corpus* skripsi sebagian besar masih bergantung pada metode LDA. Studi seperti yang dilakukan Nugraha dan Nugraheni (2024) memang berhasil memetakan topik, namun terbatas pada analisis statis yang mengabaikan konteks semantik dan tidak melacak evolusi topik. Kedua, penelitian yang telah mengadopsi BERTopic, metode yang lebih modern dan cenderung mengaplikasikannya pada *corpus* non-akademik seperti *tweet* media sosial seperti pada penelitian Diyasa (2023) atau penelitian artikel berita oleh Nugroho (2023), yang karakteristik teksnya (pendek, informal) sangat berbeda dengan abstrak skripsi yang formal dan padat secara teknis.

Bahkan, studi yang berhasil menggabungkan BERTopic dengan *corpus* skripsi pada penelitian Riyantoni (2024) pun masih terbatas pada pemetaan statis dan tidak menyertakan *Dynamic Topic Analysis* (DTA) atau perbandingan *baseline* dengan LDA. Oleh karena itu, kebaruan (*novelty*) penelitian ini terletak pada penerapan komprehensif BERTopic berbasis IndoBERT secara khusus untuk analisis *temporal* (DTA) pada korpus skripsi akademik berbahasa Indonesia, sekaligus memvalidasi kinerjanya secara kuantitatif terhadap *baseline* LDA pada *corpus* yang sama.

Keunggulan utama BERTopic untuk penelitian ini adalah dukungannya yang superior terhadap *Dynamic Topic Analysis* (DTA). Berbeda dengan model dinamis tradisional yang inferensinya tidak stabil, BERTopic pertama-

tama mengidentifikasi kluster topik global yang konsisten di seluruh *corpus*. Kemudian, model ini memetakan kluster global tersebut ke dalam segmen-segmen waktu (misalnya, per tahun) untuk dianalisis. Pendekatan ini memungkinkan analisis evolusi bobot dan kata kunci topik dari tahun ke tahun secara akurat. Dengan menerapkan metodologi ini pada *corpus* skripsi Informatika Universitas Jenderal Soedirman, penelitian ini bertujuan menyediakan pemetaan kuantitatif dan visualisasi tren riset yang akurat, guna mengidentifikasi topik yang muncul dan menurun sebagai *data-driven insights* yang valid untuk perencanaan kurikulum.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan di atas, maka penulis menuangkan rumusan masalah sebagai berikut:

1. Bagaimana mengimplementasikan *Neural Topic Modeling* (BERTopic) dengan menggunakan *pre-trained language model* (IndoBERT) untuk mengidentifikasi topik-topik riset yang koheren pada dokumen skripsi Informatika berbahasa Indonesia?
2. Bagaimana pola evolusi, pergeseran, dan perkembangan topik riset skripsi Informatika dari waktu ke waktu melalui metode *Dynamic Topic Analysis* (DTA)?
3. Bagaimana perbandingan kualitas kinerja model BERTopic berbasis IndoBERT dengan metode *Topic Modeling* tradisional (seperti LDA) berdasarkan metrik *Topic Coherence* (C_v) dan *Topic Diversity* dalam menganalisis korpus skripsi ini?
4. Topik-topik riset apa saja yang teridentifikasi sebagai tren dominan, muncul (*emerging*), dan menurun (*declining*) dalam periode penelitian, berdasarkan hasil analisis evolusi topik?

1.3 Batasan Masalah

Dalam melaksanakan penelitian ini, peneliti menetapkan batasan masalah pada:

1. Sumber dan tipe data dalam penelitian ini hanya menggunakan Judul, Abstrak, Kesimpulan, dan Metadata Temporal (Tahun Publikasi) skripsi

mahasiswa informatika Universitas Jenderal Soedirman yang berhasil diakses dari repositori digital (<https://repository.unsoed.ac.id/>). Data yang digunakan merupakan hasil web *scraping*.

2. Penelitian ini tidak melibatkan analisis isi (*full-text*) skripsi dikarenakan adanya kebijakan *restricted content* pada repositori digital yang membatasi akses penuh terhadap dokumen publik secara luas.
3. Periode waktu data yang dianalisis adalah rentang waktu 2019 hingga 2025, yang didasarkan pada ketersediaan data di repositori digital.
4. Metode *Neural Topic Modeling* utama yang digunakan adalah BERTopic dengan model *embedding* IndoBERT (turunan BERT yang telah dilatih untuk Bahasa Indonesia).
5. Analisis evolusi topik (*Dynamic Topic Analysis*) dibatasi pada identifikasi perubahan frekuensi topik, bobot kata kunci dalam topik, dan kemunculan/penurunan tren topik dari waktu ke waktu. Evaluasi kinerja model difokuskan pada pengukuran metrik *Topic Coherence* (C_v) dan *Topic Diversity*, serta tidak mencakup metrik prediksi *forecasting* di masa depan.
6. Interpretasi topik (*topic labeling*) dilakukan berdasarkan analisis kualitatif dari kata kunci yang dihasilkan model dan penilaian subjektif oleh peneliti.
7. Tahap pemrosesan data teks dan pemodelan topik dilakukan menggunakan bahasa pemrograman Python, sedangkan hasil analisis dan visualisasi tren disajikan dalam bentuk dasbor interaktif berbasis web menggunakan *framework* Laravel.

1.4 Tujuan Penelitian

Adapun tujuan yang menjadi fokus utama dari dilaksanakannya penelitian ini adalah sebagai berikut:

1. Mengimplementasikan *Neural Topic Modeling* (BERTopic) berbasis IndoBERT untuk mengidentifikasi kluster topik dan kata kunci yang koheren dari dokumen abstrak skripsi Informatika.
2. Melakukan evaluasi komparatif antara kinerja model BERTopic-IndoBERT dengan metode *Topic Modeling* tradisional (LDA) untuk

memvalidasi superioritas metodologisnya.

3. Menganalisis pola evolusi, pergeseran, dan perkembangan topik riset skripsi dari waktu ke waktu melalui *Dynamic Topic Analysis* (DTA), serta memvisualisasikannya ke dalam sebuah dasbor interaktif berbasis web agar lebih mudah dieksplorasi.
4. Memberikan *data-driven insights* mengenai tren riset yang teridentifikasi dominan, muncul (*emerging*), dan menurun (*declining*) selama periode penelitian.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi atau manfaat bagi berbagai pihak, yang dapat dijabarkan sebagai berikut:

1. Bagi Instansi
 - a) Menyediakan *data-driven insights* yang valid melalui sistem dasbor interaktif yang mempermudah pemantauan dan visualisasi tren evolusi topik riset skripsi dari tahun ke tahun.
 - b) Mendukung proses pengambilan keputusan.
2. Bagi Mahasiswa
 - a) Menambah wawasan mengenai lanskap riset Informatika secara komprehensif, khususnya tren yang didukung oleh data dan analisis *Deep Learning*.
3. Bagi Institusi
 - a) Dengan adanya analisis evolusi topik riset, hasil penelitian ini berfungsi sebagai referensi akademik strategis, khususnya di bidang Informatika, yang secara spesifik menunjukkan tren topik yang berkembang atau menurun di lingkungan universitas.

BAB II

TINJAUAN PUSTAKA

2.1 Skripsi

Skripsi adalah karya tulis ilmiah yang menjadi syarat wajib untuk memperoleh gelar sarjana (S1) di perguruan tinggi Indonesia, di mana skripsi berisi paparan hasil penelitian yang membahas suatu masalah atau fenomena dalam bidang ilmu tertentu dengan menerapkan prinsip-prinsip ilmiah yang berlaku, seperti logis, sistematis, dan objektif berdasarkan data valid yang diperoleh melalui studi pustaka, penelitian lapangan, atau pengembangan eksperimental (Syahputra & Rikki, 2021). Skripsi juga menjadi bukti kemampuan akademik mahasiswa dalam menerapkan pengetahuan dan keterampilan penelitian yang telah dipelajari selama perkuliahan, serta menjadi indikator ketercapaian kompetensi lulusan, khususnya dalam penguasaan konsep teoretis dan kemampuan memformulasikan penyelesaian masalah secara prosedural (Syahputra & Rikki, 2021).

Dalam konteks pendidikan tinggi di Indonesia, skripsi merupakan tugas akhir yang harus diselesaikan mahasiswa setelah menempuh seluruh mata kuliah, dengan tujuan mengembangkan potensi dan pengalaman belajar mahasiswa secara menyeluruh (Faizah dkk., 2023). Proses penyusunan skripsi melibatkan berbagai tahapan, mulai dari pemilihan topik, penyusunan proposal, pelaksanaan penelitian, hingga penulisan dan pertanggungjawaban hasil penelitian dalam sidang akademik (Faizah dkk., 2023). Skripsi juga mencerminkan kemampuan mahasiswa dalam berpikir kritis, analitis, serta menerapkan metodologi penelitian yang sesuai dengan bidang keilmuannya (Susetyo & Noermanzah, 2020).

Selain itu, skripsi memiliki peran penting dalam membiasakan mahasiswa untuk menulis karya ilmiah yang memenuhi standar akademik, baik dari segi struktur, penggunaan bahasa, maupun etika penulisan (Susetyo & Noermanzah, 2020). Penggunaan bahasa Indonesia yang baik dan benar dalam penulisan skripsi sangat ditekankan, karena skripsi merupakan cerminan kompetensi dan integritas ilmiah mahasiswa (Shalima & Wijayanti, 2020). Dengan demikian, skripsi tidak hanya menjadi syarat administratif kelulusan, tetapi juga sarana pengembangan kemampuan akademik, penelitian, dan

penulisan ilmiah mahasiswa (Shalima & Wijayanti, 2020; Susetyo & Noermanzah, 2020).

2.2 Text Mining

Text mining merupakan salah satu disiplin ilmu yang menggabungkan teknik-teknik dari *machine learning*, *natural language processing* (NLP), dan *data mining* untuk mengekstrak informasi bermakna dari koleksi dokumen teks yang tidak terstruktur (Dogra dkk., 2022). Dalam konteks penelitian kontemporer, *text mining* berfungsi sebagai jembatan antara data analitik tradisional dan pemrosesan bahasa natural yang canggih, memungkinkan organisasi untuk mengubah volume besar data tekstual menjadi *insight* yang *actionable* dan terukur (Shi, 2024). Proses *text mining* melibatkan serangkaian tahapan sistematis dimulai dari *text preprocessing* yang mencakup pembersihan data, normalisasi teks, penghilangan *stopwords*, dan tokenisasi hingga representasi teks dalam format numerik yang dapat diproses oleh algoritma *machine learning* (Dogra dkk., 2022).

2.3 Web Scraping

Dalam penelitian berbasis *data mining* dan pemrosesan bahasa alami (NLP), tahap pengumpulan data merupakan langkah fundamental. *Web scraping* didefinisikan sebagai teknik ekstraksi data otomatis yang digunakan untuk mengambil informasi dari situs web yang tidak menyediakan akses data terstruktur melalui API (*Application Programming Interface*). Menurut Sultan dan Abdullah (2022), teknik ini menjadi solusi vital untuk mengatasi tantangan *Big Data* yang sebagian besar tersedia dalam format tidak terstruktur di internet, seperti pada platform Google Scholar atau repositori publikasi lainnya.

Proses *web scraping* bekerja dengan cara meniru interaksi manusia terhadap peramban (*browser*). Secara teknis, skrip program akan mengirimkan permintaan HTTP ke server target, mengunduh dokumen HTML (*Hypertext Markup Language*), dan kemudian melakukan *parsing* untuk memisahkan elemen data yang relevan dari elemen desain antarmuka. Ulfah dan Najiah (2023) dalam penelitiannya mengenai ekstraksi data jurnal SINTA, menjelaskan bahwa penggunaan *framework* seperti Selenium WebDriver dengan bahasa

pemrograman Python sangat efektif untuk menangani situs web dinamis. Berbeda dengan pustaka statis, Selenium mampu mengotomatisasi interaksi seperti pengguliran halaman (*scrolling*) dan navigasi tombol yang sering ditemukan pada portal jurnal modern.

Penerapan *web scraping* tidak hanya terbatas pada pengambilan teks, tetapi juga transformasi data. Rizquina dan Ratnasari (2023) menekankan bahwa data mentah hasil *scraping* harus melalui tahap pembersihan dan penyimpanan ke dalam format terstruktur (seperti CSV atau Excel) agar dapat dianalisis lebih lanjut. Dalam konteks penelitian evolusi topik, teknik ini memungkinkan peneliti untuk menyusun korpus data judul dan abstrak dalam jumlah masif secara efisien, yang mustahil dilakukan melalui penyalinan manual.

2.4 Natural Language Processing (NLP)

Natural Language Processing (NLP) atau Pemrosesan Bahasa Alami merupakan cabang dari kecerdasan buatan (*Artificial Intelligence*) yang berfokus pada interaksi antara komputer dan bahasa manusia. Tujuan utama NLP adalah memungkinkan komputer untuk membaca, memahami, dan menafsirkan bahasa manusia dengan cara yang bernilai dan bermakna. Menurut Khurana dkk. (2023), NLP modern tidak lagi hanya bergantung pada aturan tata bahasa statis (*rule-based*), melainkan telah beralih ke pendekatan berbasis data (*data-driven*) yang memanfaatkan algoritma *Machine Learning* dan *Deep Learning* untuk mengenali pola linguistik yang kompleks.

Dalam konteks analisis teks, NLP bertugas mentransformasi data teks tidak terstruktur menjadi format numerik yang dapat diproses oleh mesin. Tantangan utama dalam NLP, khususnya untuk Bahasa Indonesia, adalah kompleksitas morfologi dan variasi kata. Wilie dkk. (2020) dalam penelitian seminalnya mengenai *IndoNLU*, menjelaskan bahwa pengembangan model NLP untuk Bahasa Indonesia memerlukan pendekatan khusus karena adanya penggunaan imbuhan (afiksasi) dan kata serapan yang dinamis.

Perkembangan terkini dalam NLP ditandai dengan munculnya model bahasa berbasis *Transformer*, seperti BERT (*Bidirectional Encoder Representations from Transformers*). Berbeda dengan metode tradisional seperti *Bag-of-Words* (BoW) yang mengabaikan urutan kata, pendekatan

berbasis *Transformer* mampu menangkap konteks semantik kata dari dua arah (kiri-ke-kanan dan kanan-ke-kiri). Hal ini memungkinkan representasi teks yang lebih kaya dan akurat, yang sangat krusial dalam tugas-tugas tingkat lanjut seperti pemodelan topik (*topic modeling*) dan klasifikasi teks (Otter dkk., 2021).

2.5 Text Preprocessing

Text Preprocessing atau pra-pemrosesan teks adalah tahapan fundamental dalam *data mining* yang bertujuan mengubah data teks mentah tidak terstruktur menjadi format baku yang siap dianalisis. Data yang bersumber dari internet, seperti hasil *web scraping*, umumnya mengandung banyak *noise* berupa simbol, angka, atau format HTML yang tidak relevan dengan konten utama. Khairunnisa dkk. (2021) dalam penelitiannya menyimpulkan bahwa penerapan teknik preprocessing yang tepat memiliki dampak signifikan terhadap akurasi model, karena teknik ini membantu mereduksi dimensi fitur dan memfokuskan algoritma pada kata-kata yang memiliki bobot informasi tinggi.

Dalam pemrosesan dokumen berbahasa Indonesia, tahapan standar *preprocessing* biasanya meliputi:

1. *Case Folding*: Menyeragamkan karakter menjadi huruf kecil untuk menjaga konsistensi.
2. *Cleaning*: Menghapus karakter non-alfanumerik, tanda baca, dan angka.
3. *Tokenizing*: Memecah kalimat menjadi unit kata tunggal (token).
4. *Stopword Removal*: Menghapus kata hubung umum (seperti "dan", "yang", "dari") yang sering muncul namun minim makna semantik.
5. *Stemming*: Mengubah kata berimbuhan menjadi kata dasar. (Nafi' dkk., 2024) mencatat bahwa untuk Bahasa Indonesia, penggunaan pustaka Sastrawi merupakan standar umum dalam menangani kompleksitas morfologi kata yang memiliki awalan dan akhiran.

Meskipun demikian, pendekatan *preprocessing* bersifat adaptif tergantung pada algoritma yang digunakan. Dalam penelitian yang menggunakan model berbasis *Transformer* seperti BERT (*Bidirectional Encoder Representations from Transformers*) atau IndoBERT, tahapan seperti *stemming* sering kali ditiadakan. Devlin dkk. (2019) menjelaskan bahwa model BERT dilatih untuk

memahami konteks kalimat secara utuh, sehingga pemotongan kata menjadi bentuk dasar justru berpotensi menghilangkan informasi morfologis dan nuansa makna yang penting bagi model untuk membentuk representasi topik yang akurat.

2.6 Topic Modeling

Topic Modeling atau pemodelan topik adalah salah satu teknik dalam *Natural Language Processing* (NLP) dan *Machine Learning* yang bertujuan untuk menemukan struktur tematik tersembunyi (*latent structure*) di dalam sekumpulan dokumen yang besar. Metode ini termasuk dalam kategori *unsupervised learning* (pembelajaran tanpa pengawasan), di mana algoritma bekerja tanpa adanya label data sebelumnya untuk mengelompokkan kata-kata yang sering muncul bersamaan ke dalam kluster topik yang koheren (Vayansky & Kumar, 2020).

Secara tradisional, metode yang paling populer digunakan adalah *Latent Dirichlet Allocation* (LDA). LDA bekerja dengan pendekatan probabilistik generatif, yang mengasumsikan bahwa setiap dokumen adalah campuran dari berbagai topik, dan setiap topik adalah campuran dari berbagai kata. Namun, Jelodar dkk. (2019) mencatat bahwa metode tradisional seperti LDA memiliki keterbatasan dalam menangkap konteks semantik kata, terutama pada dokumen pendek, karena LDA menggunakan pendekatan *Bag-of-Words* (BoW) yang mengabaikan urutan kata.


Untuk mengatasi keterbatasan tersebut, berkembanglah pendekatan *Neural Topic Modeling*. Pendekatan ini memanfaatkan *word embeddings* dan jaringan saraf tiruan (*neural networks*) untuk merepresentasikan kata dan dokumen dalam ruang vektor. Dengan metode ini, hubungan semantik antar kata (misalnya, kata "komputer" dan "laptop" yang dianggap dekat secara makna meskipun katanya berbeda) dapat ditangkap dengan lebih baik dibandingkan metode statistik konvensional (Grootendorst, 2022).

2.7 Latent Dirichlet Allocation (LDA)

Latent Dirichlet Allocation (LDA) merupakan model generatif probabilistik untuk koleksi data diskrit, seperti korpus teks, yang pertama kali diperkenalkan

oleh Blei dkk. (2003). LDA memodelkan dokumen sebagai campuran acak (*random mixture*) dari berbagai topik laten, di mana setiap topik itu sendiri dikarakteristikan oleh distribusi probabilitas terhadap kata-kata.

Secara konseptual, LDA mengasumsikan bahwa topik-topik tersebut tersembunyi (*latent*) dan harus diinferensi dari kata-kata yang terobservasi dalam dokumen. Struktur dependensi antar variabel dalam model LDA divisualisasikan menggunakan notasi pelat (*plate notation*) sebagaimana ditunjukkan pada Gambar 2.1.



Gambar 2. 1 Representasi Model Grafis LDA (Blei dkk., 2003).

Berdasarkan Gambar 2.1, struktur model LDA terdiri dari tiga tingkat representasi:

1. Tingkat Korpus (Parameter α dan β): Parameter yang diasumsikan disampel satu kali dalam proses pembentukan korpus dan berlaku untuk seluruh dokumen.
2. Tingkat Dokumen (Variabel θ): Variabel distribusi topik yang disampel satu kali untuk setiap dokumen (ditunjukkan oleh pelat luar M).
3. Tingkat Kata (Variabel z dan w): Variabel penugasan topik (z) dan kata (w) yang disampel berulang kali untuk setiap kata dalam dokumen (ditunjukkan oleh pelat dalam N).

Proses generatif untuk setiap dokumen w dalam korpus D diasumsikan mengikuti langkah-langkah berikut:

1. Menentukan jumlah kata N berdasarkan distribusi Poisson.
2. Memilih distribusi topik θ dari distribusi Dirichlet dengan parameter α ($\theta \sim \text{Dir}(\alpha)$).

3. Untuk setiap kata ke- n dari total N kata dalam dokumen:
 - a. Memilih topik z_n dari distribusi Multinomial(θ).
 - b. Memilih kata w_n dari probabilitas bersyarat $p(w_n|z_n, \beta)$ yang bergantung pada topik z_n tersebut.

Meskipun LDA menjadi metode standar dalam pemodelan topik, pendekatan ini memiliki keterbatasan teoritis yang signifikan. Blei dkk., (2003) menyatakan bahwa LDA didasarkan pada asumsi *Bag-of-Words*, di mana urutan kata dalam dokumen diabaikan dan dianggap dapat dipertukarkan (*exchangeable*). Akibatnya, struktur kalimat yang kompleks dan nuansa semantik yang bergantung pada konteks urutan kata tidak dapat ditangkap sepenuhnya oleh model ini. Selain itu, dimensi k (jumlah topik) pada distribusi Dirichlet diasumsikan diketahui dan tetap (*fixed*), sehingga mengharuskan peneliti untuk menentukan jumlah topik secara manual sebelum proses pelatihan. Keterbatasan dalam menangkap konteks semantik dan rigiditas penentuan topik inilah yang menjadi dasar pengembangan metode berbasis *embedding* saraf (*Neural Topic Modeling*) dalam penelitian ini.

2.8 Transformer

Transformer merupakan arsitektur jaringan saraf (*neural network*) yang dirancang secara spesifik untuk menangani tugas pemrosesan bahasa alami (*Natural Language Processing*) dengan efisiensi tinggi (Vaswani dkk., 2023). Berbeda dengan model pendahulunya yang menggunakan lapisan rekursif seperti *Recurrent Neural Network* (RNN) atau konvolusional seperti *Convolutional Neural Network* (CNN) untuk memproses urutan data, arsitektur Transformer sepenuhnya mengandalkan mekanisme yang disebut *attention*. Vaswani dkk. (2023) menekankan keunggulan utama dari pendekatan ini adalah kemampuannya untuk memproses data secara paralel dan mempelajari hubungan dependensi jarak jauh antar kata dalam kalimat dengan lebih efektif.

Mekanisme inti yang menjadi fondasi arsitektur ini adalah *Self-Attention*. Mekanisme ini memungkinkan model untuk mempelajari korelasi dan bobot kepentingan antar kata dalam sebuah kalimat, memastikan model memahami bagaimana konteks makna suatu kata dipengaruhi oleh kata-kata lain di sekitarnya. Vaswani dkk. (2023) merumuskan mekanisme *attention* ini sebagai

fungsi pemetaan vektor *query* (Q), *key* (K), dan *value* (V) menggunakan persamaan (1) berikut:


$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (1)$$

Keterangan :

- Q : Matriks *Query*.
- K : Matriks *Key*.
- V : Matriks *Value*.
- d_k : Dimensi vektor *Key*.
- softmax* : Fungsi aktivasi untuk menghitung bobot probabilitas.

Di mana d_k adalah dimensi dari key, dan pembagian dengan $\sqrt{d_k}$ berfungsi sebagai faktor penskalaan (*scaling factor*) untuk mencegah hasil dot product menjadi terlalu besar yang dapat menyebabkan gradien menjadi sangat kecil pada fungsi *softmax*.

Secara struktural, *Transformer* mengadopsi kerangka kerja *encoder-decoder*. *Encoder* bertugas memetakan urutan simbol input $(x_1, \dots, x_n)$ menjadi urutan representasi kontinu $z = (z_1, \dots, z_n)$. Berdasarkan z , *decoder* kemudian menghasilkan urutan simbol output $(y_1, \dots, y_m)$ secara autoregresif, satu elemen pada satu waktu. Visualisasi menyeluruh mengenai arsitektur *Transformer* beserta komponen-komponennya dapat dilihat pada Gambar 2.2.



Gambar 2.2 Model Arsitektur Transformer (Vaswani dkk., 2023)

Berdasarkan Gambar 2.2, arsitektur ini terdiri dari komponen-komponen utama berikut:

2.8.1 Encoder

Encoder Terdiri dari tumpukan $N = 6$ lapisan identik. Setiap lapisan memiliki dua sub-lapisan: mekanisme *multi-head self-attention* dan jaringan *feed-forward* yang terhubung penuh secara posisi (*position-wise*).


Di sekeliling setiap sub-lapisan, diterapkan koneksi residual (*residual connection*), diikuti oleh normalisasi lapisan (*layer normalization*).

2.8.2 Decoder

Decoder terdiri dari tumpukan $N = 6$ lapisan identik. Selain dua sub-lapisan yang ada pada *encoder*, *decoder* menyisipkan sub-lapisan ketiga yang melakukan *multi-head attention* terhadap output dari tumpukan *encoder*. Mekanisme *self-attention* pada *decoder* dimodifikasi dengan *masking* untuk mencegah posisi tertentu memperhatikan posisi-posisi selanjutnya, memastikan bahwa prediksi untuk posisi i hanya bergantung pada output yang diketahui di posisi kurang dari i .

2.8.3 Multi-Head Attention

Pengembangan yang diperkenalkan oleh Vaswani dkk. (2023) dalam arsitektur Transformer adalah mekanisme *Multi-Head Attention*. Mekanisme ini dirancang untuk mengatasi keterbatasan *single attention head* yang hanya mampu memproses satu representasi fokus pada satu waktu. Dalam pendekatan *single head*, model sering kali kesulitan untuk menangkap berbagai nuansa hubungan antar kata (seperti hubungan sintaksis dan semantik) secara bersamaan karena adanya proses perataan bobot atensi. Untuk mengatasi hal ini, arsitektur *Multi-Head Attention* memecah proses atensi menjadi beberapa jalur paralel. Visualisasi mekanisme ini dapat dilihat pada Gambar 2.3.



Gambar 2. 3 *Multi-Head Attention* pada Transformer (Vaswani dkk., 2023)

Berdasarkan Gambar 2.3, Vaswani dkk. (2023) menjelaskan bahwa alih-alih melakukan fungsi atensi tunggal pada *query*, *key*, dan *value* dengan dimensi penuh (d_{model}), mekanisme ini melakukan proyeksi linear terhadap *query*, *key*, dan *value* sebanyak h kali ke dalam sub-ruang representasi yang berbeda (d_k , d_q , dan d_v). Pada setiap hasil proyeksi tersebut, fungsi *Scaled Dot-Product Attention* dijalankan secara paralel dan independen. Proses ini menghasilkan vektor *output* untuk setiap "kepala" (*head*) yang kemudian digabungkan kembali (*concatenated*) dan diproyeksikan sekali lagi melalui lapisan linear akhir untuk menghasilkan representasi *output* yang utuh.

Pendekatan ini memberikan keunggulan utama berupa kemampuan model untuk memperhatikan (*attend*) informasi dari berbagai sub-ruang representasi pada posisi yang berbeda secara simultan. Sebagai contoh, satu *head* dapat fokus mempelajari struktur tata bahasa, sementara *head* lainnya fokus memahami referensi semantik antar kata, sehingga model memiliki


pemahaman konteks yang jauh lebih kaya dan komprehensif dibandingkan model sebelumnya.

2.9 BERT

BERT (*Bidirectional Encoder Representations from Transformers*) merupakan model representasi bahasa mutakhir yang diperkenalkan oleh Devlin dkk., (2019). Berbeda dengan model pendahulunya yang memproses teks secara searah (*unidirectional*) atau menggunakan arsitektur encoder-decoder untuk penerjemahan, BERT didesain menggunakan arsitektur *multi-layer bidirectional Transformer encoder*. Inovasi fundamental dari BERT terletak pada penerapan mekanisme *self-attention* yang bersifat dua arah (*deeply bidirectional*). Mekanisme ini memungkinkan model untuk mempelajari konteks suatu kata dengan memperhatikan seluruh kata lain di sekitarnya baik dari arah kiri maupun kanan secara simultan pada setiap lapisan jaringan. Kemampuan ini menjadikan BERT sangat efektif dalam menangkap ambiguitas semantik dan nuansa linguistik yang kompleks, yang sangat krusial dalam analisis teks akademis seperti judul dan abstrak skripsi.

2.9.1 Representasi Input

Sebelum data teks dapat diproses oleh lapisan *encoder*, BERT mengubah teks mentah menjadi vektor numerik melalui mekanisme *embedding* gabungan. Sebagaimana diilustrasikan pada Gambar 2.4, representasi input untuk setiap token dikonstruksi dengan menjumlahkan tiga elemen vektor yang berbeda.




Gambar 2. 4 Representasi Input BERT (Devlin dkk., 2019)

Berdasarkan Gambar 2.4, ketiga elemen penyusun tersebut adalah:

1. *Token Embeddings*: Representasi vektor kata yang dihasilkan menggunakan algoritma tokenisasi *WordPiece*. Setiap urutan input diawali dengan token spesial [CLS] (*Classification*) yang berfungsi sebagai representasi agregat seluruh kalimat, dan dipisahkan oleh token [SEP] (*Separator*) sebagai penanda batas kalimat.
2. *Segment Embeddings*: Vektor penanda yang berfungsi untuk membedakan apakah sebuah token merupakan bagian dari kalimat pertama (Kalimat A) atau kalimat kedua (Kalimat B).
3. *Position Embeddings*: Vektor yang disuntikkan untuk memberikan informasi mengenai posisi absolut atau relatif token di dalam urutan (*sequence*), mengingat arsitektur Transformer tidak memiliki mekanisme rekurensi (*recurrence*) untuk membaca urutan waktu.

2.9.2 Mekanisme Pra-Pelatihan (*Pre-training Objectives*)

Keunggulan performa BERT diasosiasikan dengan strategi pelatihannya yang menerapkan dua tugas *unsupervised* secara bersamaan pada korpus berskala besar. Alur kerja prosedur pra-pelatihan (*pre-training*) dan penyesuaian (*fine-tuning*) ini divisualisasikan pada Gambar 2.5.



Gambar 2. 5 *Pre-Training & Fine-Tuning* pada BERT (Devlin dkk., 2019)

Mengacu pada sisi kiri Gambar 2.5, dua objektif pembelajaran tersebut meliputi:

1. *Masked Language Modeling* (MLM): Berbeda dengan pemodelan bahasa standar yang memprediksi kata berikutnya, BERT

menyembunyikan (*masking*) 15% dari token input secara acak. Model kemudian dilatih untuk memprediksi token asli yang disembunyikan tersebut (ditandai dengan panah Mask LM) hanya berdasarkan konteks dari token-token lain di sekitarnya. Pendekatan ini memaksa model untuk membangun pemahaman konteks yang mendalam dan menyeluruh.

2. *Next Sentence Prediction* (NSP): Untuk menangkap hubungan logis antar kalimat, BERT dilatih melakukan klasifikasi biner untuk memprediksi apakah kalimat kedua adalah kelanjutan dari kalimat pertama. Prediksi ini dilakukan menggunakan output vektor dari token [CLS] (ditandai dengan panah NSP).

Setelah melalui tahap pra-pelatihan, model menghasilkan parameter awal (*pre-trained parameters*) yang kaya akan informasi linguistik. Parameter ini kemudian dapat digunakan untuk inisialisasi pada tahap *fine-tuning* (sisi kanan Gambar 2.2) untuk berbagai tugas spesifik, termasuk pemodelan topik.

2.10 IndoBERT

Meskipun model multibahasa seperti mBERT (*Multilingual BERT*) memiliki kemampuan memproses Bahasa Indonesia, model tersebut dilatih pada lebih dari 100 bahasa sekaligus yang sering kali menyebabkan dilusi representasi (*curse of multilinguality*). Untuk mengatasi keterbatasan ini, penelitian ini menggunakan IndoBERT, model representasi bahasa pra-pelatihan (*pre-trained language model*) yang dikembangkan khusus untuk Bahasa Indonesia oleh Wilie dkk., (2020).

IndoBERT dibangun di atas arsitektur BERT-Base dengan konfigurasi 12 lapisan *encoder*, 768 dimensi *hidden size*, dan 12 *attention heads*, dengan total parameter mencapai 110 juta parameter. Arsitektur ini memungkinkan model untuk mempelajari representasi vektor kontekstual yang mendalam dari teks input.

2.10.1 Dataset Pra-Pelatihan (Indo4B)

Keunggulan fundamental IndoBERT terletak pada skala dan variasi data pelatihannya. Model ini dilatih menggunakan dataset masif bernama Indo4B yang memiliki ukuran total 23.43 GB. Berdasarkan dokumentasi statistik korpus, Indo4B mencakup total 3.581.301.476 kata (sekitar 3,6 miliar kata) dan 275.301.176 kalimat.

Komposisi data ini dirancang untuk mencakup berbagai gaya bahasa (*style*), mulai dari formal, kolokial (bahasa sehari-hari), hingga campuran (*mixed*). Rincian statistik sumber data utama Indo4B disajikan pada Tabel 2.1.

Tabel 2. 1 Statistik Dataset Indo4B (Wilie dkk., 2020)

Dataset	Jumlah Kata (# Words)	Ukuran (Size)	Gaya Bahasa (Style)
OSCAR (Web Corpus)	2,279,761,186	14.9 GB	Mixed
CoNLLu Common Crawl	905,920,488	6.1 GB	Mixed
Twitter (Crawl + UI)	131,843,378	~685 MB	Colloquial
Wikipedia (Dump + CoNLLu)	138,637,209	~951 MB	Formal
OpenSubtitles	105,061,204	664.8 MB	Mixed
Berita (Tempo + Kompas)	9,570,967	~66 MB	Formal
Lainnya (TED, BPPT, dll.)	10,507,044	~20 MB	Formal/Mixed
TOTAL	3,581,301,476	23.43 GB	-

Sumber: Diolah dari Wilie dkk., (2020).

Berdasarkan Tabel 2.1, dominasi data berasal dari korpus web (OSCAR dan Common Crawl) dengan gaya bahasa campuran (*mixed*). Namun, poin krusial untuk penelitian ini adalah keberadaan porsi data berlabel "Formal" yang signifikan, khususnya dari Wikipedia (>138 juta kata) dan Portal Berita (>9,5 juta kata). Ketersediaan ratusan juta kata dengan struktur

bahasa baku ini memastikan bahwa IndoBERT memiliki representasi yang kuat untuk memahami istilah akademis dan struktur kalimat formal yang menjadi karakteristik utama dalam abstrak skripsi Informatika.

2.10.2 Konfigurasi dan Performa *Benchmark* (IndoNLU)

Strategi pelatihan IndoBERT dirancang untuk mengoptimalkan pemahaman konteks panjang melalui dua fase pelatihan (*phase one* dengan urutan 128 token dan *phase two* dengan 512 token). Efektivitas strategi ini dibuktikan melalui evaluasi pada *IndoNLU Benchmark* yang mencakup tugas klasifikasi dan pelabelan urutan (*sequence labeling*). Sebagaimana ditunjukkan pada Tabel 2.2, IndoBERT secara konsisten mengungguli model multibahasa mBERT.

Tabel 2. 2 Perbandingan Performa Model (Wilie dkk., 2020)

Model	Rata-rata Skor Klasifikasi	Rata-rata Skor Pelabelan Urutan
Scratch (Tanpa Pre-training)	66.49	44.03
fastText-indo4b	75.97	58.28
mBERT (Multilingual BERT)	78.54	76.36
IndoBERT-Base (+ phase two)	85.71	77.34
IndoBERT-Large (+ phase two)	88.02	81.26


Sumber: Diolah dari Wilie dkk., (2020).

Berdasarkan Tabel 2.2, model IndoBERT-Base (dengan *phase two*) mencapai skor rata-rata klasifikasi sebesar 85.71, yang jauh lebih tinggi dibandingkan mBERT yang hanya mencapai 78.54. Keunggulan margin performa yang signifikan ini memvalidasi pemilihan IndoBERT sebagai model *embedding* yang paling optimal untuk menangkap semantik topik dalam korpus skripsi berbahasa Indonesia.

2.11 BERTopic

BERTopic merupakan teknik pemodelan topik (*topic modeling*) mutakhir yang memanfaatkan arsitektur *Transformer* dan algoritma klastering berbasis kepadatan untuk mengekstraksi topik yang koheren dari sekumpulan dokumen. Berbeda dengan pendekatan tradisional seperti *Latent Dirichlet Allocation* (LDA) yang mengandalkan pendekatan statistik *Bag-of-Words*, BERTopic mengadopsi pendekatan modular yang menggabungkan representasi semantik mendalam dengan teknik klastering canggih. Grootendorst, (2022) mendefinisikan BERTopic sebagai kerangka kerja yang menghasilkan topik dengan cara mengelompokkan vektor dokumen (*embeddings*) dan kemudian menerapkan variasi TF-IDF berbasis kelas (c-TF-IDF) untuk merepresentasikan topik tersebut.

Keunggulan utama BERTopic terletak pada kemampuannya menjaga konteks semantic. Egger dan Yu. (2022) dalam studi komparasinya menyoroti bahwa BERTopic sangat fleksibel dan efektif untuk berbagai jenis data teks, termasuk teks pendek seperti media sosial, karena kemampuannya memanfaatkan *Pre-trained Language Models* (seperti BERT atau IndoBERT) yang telah dilatih pada korpus besar. Secara visual, alur kerja arsitektur BERTopic mulai dari input hingga terbentuknya topik dapat dilihat pada Gambar 2.6.




Gambar 2. 6 Arsitektur dan Alur Kerja BERTopic (Grootendorst, 2022)

Selain itu, BERTopic memiliki keunggulan signifikan dalam melakukan *Dynamic Topic Analysis* (DTA). Grootendorst, (2022) menjelaskan bahwa BERTopic dapat memodelkan evolusi topik sepanjang waktu (*topics over time*) dengan memvariasikan representasi c-TF-IDF berdasarkan *timestamp* dokumen, tanpa perlu melatih ulang model klasterisasi untuk setiap periode waktu. Fitur ini sangat krusial untuk menganalisis tren riset skripsi yang bersifat dinamis dari tahun ke tahun.

2.11.1 Document Embedding (Sentence-BERT)

Fase fundamental pertama dalam arsitektur BERTopic adalah mentransformasikan dokumen teks tak terstruktur ke dalam ruang vektor berdimensi tetap (*fixed-sized dense vectors*). Dalam penelitian ini, proses ekstraksi representasi fitur tekstual tersebut dilakukan menggunakan arsitektur *Sentence-BERT* (SBERT) yang diusulkan oleh Reimers & Gurevych (2019). Berbeda dengan arsitektur BERT konvensional yang beroperasi pada level token dan mensyaratkan komputasi berpasangan (*pairwise computation*) dengan kompleksitas tinggi untuk mengukur similaritas antar kalimat, SBERT mengadaptasi model pra-pelatihan BERT melalui implementasi struktur jaringan *siamese* (*siamese network*).



Gambar 2. 7. Arsitektur Sentence-BERT pada saat inferensi (Reimers & Gurevych, 2019)

Berdasarkan Gambar 2.7, struktur *siamese* memungkinkan SBERT untuk memproses dua instans teks secara paralel dan independen. Pada tahap inferensi, teks masukan didistribusikan ke dalam jaringan BERT yang saling berbagi bobot parameter (*tied weights*). Representasi keluaran dari lapisan Transformer tersebut selanjutnya direduksi melalui operasi *pooling* (pada umumnya menggunakan strategi *MEAN pooling*). Lapisan *pooling* ini berfungsi krusial untuk mengagregasi representasi tingkat token menjadi sebuah vektor kalimat tunggal yang merepresentasikan konteks semantik secara holistik (direpresentasikan sebagai matriks u dan v).

Dengan merepresentasikan setiap dokumen abstrak sebagai vektor independen yang kaya akan atribut semantik (*semantic-rich*), kalkulasi jarak semantik antar dokumen dapat dieksekusi secara komputasional efisien menggunakan metrik evaluasi seperti *Cosine Similarity*. Secara matematis, tingkat kesamaan kosinus antara dua vektor dokumen u dan v dirumuskan pada persamaan (X) berikut:

$$\text{similarity}(u, v) = \frac{u \cdot v}{|u||v|} \quad (2)$$

Vektor-vektor hasil *embedding* dokumen inilah yang selanjutnya dijadikan sebagai data masukan (*input*) pada tahap reduksi dimensi (UMAP) dan algoritma klusterisasi (HDBSCAN) guna mengonstruksi topik-topik laten yang koheren di dalam *pipeline* algoritma BERTopic.

2.11.2 Dimensionality Reduction

Vektor *embedding* yang dihasilkan oleh model transformer (seperti IndoBERT) memiliki dimensi yang sangat tinggi (misalnya, 768 dimensi), yang menyebabkan fenomena *curse of dimensionality* di mana jarak antar titik data menjadi kurang bermakna untuk algoritma klusterisasi. Untuk mengatasi hal ini, BERTopic menggunakan algoritma *Uniform Manifold Approximation and Projection* (UMAP) yang diperkenalkan oleh McInnes dkk., (2020).

UMAP bekerja dengan membangun graf tetangga terdekat (*nearest neighbor graph*) dalam dimensi tinggi dan kemudian memproyeksikan graf

tersebut ke dalam dimensi yang lebih rendah (biasanya 2 hingga 5 dimensi) dengan tetap mempertahankan struktur topologi data. Keunggulan utama UMAP dibandingkan teknik reduksi dimensi lain seperti t-SNE (*t-Distributed Stochastic Neighbor Embedding*) adalah kemampuannya dalam mempertahankan struktur global data sekaligus struktur lokalnya, serta efisiensi komputasi yang lebih tinggi untuk dataset berskala besar (McInnes dkk., 2020). Hal ini memastikan bahwa dokumen-dokumen yang memiliki kemiripan semantik tetap berada dalam kedekatan spasial yang rapat sebelum masuk ke tahap klusterisasi.

2.11.3 Clustering

Setelah dimensi data direduksi, BERTopic menggunakan algoritma *Hierarchical Density-Based Spatial Clustering of Applications with Noise* (HDBSCAN) untuk mengelompokkan dokumen ke dalam topik-topik laten. Algoritma ini merupakan pengembangan dari DBSCAN yang diperkenalkan oleh Campello dkk., (2013).

HDBSCAN dipilih karena pendekatannya yang berbasis densitas (*density-based*), yang memiliki dua keunggulan utama dibandingkan metode *centroid-based* seperti K-Means. Pertama, HDBSCAN tidak mengharuskan peneliti untuk menentukan jumlah kluster (k) secara apriori, melainkan menemukan jumlah kluster secara otomatis berdasarkan struktur data. Kedua, HDBSCAN mampu mendeteksi dan memisahkan *outliers* atau *noise* (dokumen yang tidak masuk ke topik manapun), yang sangat relevan dalam analisis data teks nyata yang seringkali mengandung dokumen yang tidak relevan. Menurut (Campello dkk., 2013), HDBSCAN bekerja dengan mengubah data menjadi struktur hierarkis untuk menemukan kluster yang paling stabil di berbagai tingkat densitas (epsilon), sehingga menghasilkan topik yang lebih koheren dan terpisah dengan jelas.

2.11.4 Class Based Term Frequency – Inverse Document Frequency (c-TF-IDF)

Setelah proses pengelompokan dokumen selesai, tahap krusial berikutnya adalah mengekstraksi kata kunci yang mampu merepresentasikan isi dari setiap klaster secara akurat. Metode ini dikembangkan dari algoritma dasar *Term Frequency-Inverse Document Frequency* (TF-IDF) yang diperkenalkan oleh Sparck Jones, (1972), yang secara tradisional digunakan untuk mengevaluasi bobot pentingnya sebuah kata dalam dokumen individu relatif terhadap seluruh koleksi korpus. Secara matematis, bobot TF-IDF standar dihitung dengan mengalikan frekuensi kemunculan kata (*TF*) dengan invers frekuensi dokumen (*IDF*), sebagaimana didefinisikan dalam persamaan (2) berikut (Edward Jones, t.t.):

$$TF-IDF(t, d) = TF(t, d) \times \log \left(\frac{N}{df_t} \right) \quad (3)$$

Dimana N adalah total jumlah dokumen dan df_t adalah jumlah dokumen yang mengandung kata t . Meskipun efektif untuk pencarian informasi, pendekatan ini memiliki keterbatasan dalam pemodelan topik karena bekerja pada level dokumen individu, sehingga sulit untuk menangkap esensi kolektif dari sebuah klaster topik.

Untuk mengatasi keterbatasan tersebut, BERTopic menerapkan variasi algoritma yang disebut c-TF-IDF (*Class-based TF-IDF*) yang diperkenalkan oleh Grootendorst, (2022). Inovasi utama dari metode ini adalah mengubah unit analisis dari "dokumen individu" menjadi "kelas topik". Algoritma ini menggabungkan seluruh dokumen yang berada dalam satu klaster menjadi satu dokumen besar (*class*), sehingga frekuensi kata tidak lagi dihitung per dokumen, melainkan per topik. Rumus c-TF-IDF memodifikasi komponen IDF untuk mengukur kelangkaan kata antar-topik, bukan antar-dokumen, yang didefinisikan pada persamaan (3) berikut:

$$c\text{-TF-IDF}_t = tf_{t,c} \times \log \left(1 + \frac{A}{f_t} \right) \quad (4) \text{(Grootendorst, 2022)}$$

Dalam persamaan di atas, $tf_{t,c}$ adalah frekuensi kata t dalam topik c , f_t adalah frekuensi total kata t di seluruh koleksi topik, dan A adalah rata-rata jumlah kata per topik. Dengan pendekatan ini, kata-kata yang sering muncul dalam satu topik tertentu tetapi jarang muncul di topik lain akan mendapatkan skor tinggi, menjadikannya kandidat label topik yang sangat representatif.

Dalam implementasi praktisnya pada data skripsi yang cenderung tidak seimbang (ada topik dengan jumlah dokumen sangat banyak dan ada yang sedikit), c-TF-IDF memerlukan normalisasi agar topik yang besar tidak mendominasi skor kata kunci. Oleh karena itu, diterapkan normalisasi L1 pada frekuensi kata, di mana skor frekuensi $tf_{t,c}$ dibagi dengan total jumlah kata dalam topik tersebut. Persamaan normalisasinya didefinisikan pada persamaan (4) berikut:

$$tf_{norm} = \frac{tf_{t,c}}{\sum_{t'} tf_{t',c}} \quad (5)$$

Normalisasi ini memastikan bahwa relevansi kata dapat dibandingkan secara adil antar-topik, terlepas dari seberapa besar atau kecil ukuran kluster tersebut, sehingga menghasilkan representasi topik yang *robust* dan konsisten.

2.11.5 Maximal Marginal Relevance (MMR)

Sebagai tahapan akhir dalam kerangka kerja representasi topik pada algoritma BERTopic, dilakukan proses optimasi ekstraksi kata kunci menggunakan teknik *Maximal Marginal Relevance* (MMR) yang pertama kali diperkenalkan oleh Carbonell & Goldstein (1998). Meskipun algoritma c-TF-IDF secara inheren sangat efektif dalam mengekstraksi kata kunci yang relevan untuk setiap kluster, daftar representasi yang dihasilkan sering kali memuat variasi leksikon yang secara semantik sangat identik atau

redundan (sebagai contoh, kemunculan kata "komputasi", "komputer", dan "komputerisasi" secara bersamaan pada satu topik).

Untuk mengatasi permasalahan redundansi leksikal tersebut, MMR diimplementasikan guna menyeimbangkan dua metrik utama secara simultan: tingkat relevansi (*relevance*) dan keberagaman (*diversity*). Secara matematis, algoritma MMR bekerja secara iteratif untuk menyeleksi kata kunci terbaik (w_i) berdasarkan fungsi objektif yang dirumuskan pada persamaan berikut:

$$\text{MMR} = \arg \max_{w_i \in C \setminus S} \left[\lambda \cdot \text{Sim}(w_i, t) - (1 - \lambda) \max_{w_j \in S} \text{Sim}(w_i, w_j) \right] \quad (6)$$

Keterangan :

C : Himpunan seluruh vektor kandidat kata kunci dalam suatu topik.

S : Himpunan kata kunci yang telah terpilih pada iterasi sebelumnya.

t : Vektor representasi semantik dari topik secara keseluruhan (*topic embedding*).

Sim : Fungsi untuk menghitung kedekatan jarak vektor (umumnya menggunakan *Cosine Similarity*).

λ : Parameter pembobot (*trade-off*) yang bernilai antara 0 hingga 1.

Berdasarkan persamaan di atas, algoritma ini mengevaluasi setiap kandidat kata kunci dengan memaksimalkan nilai kedekatan (similaritas) terhadap vektor topik utama ($\lambda \cdot \text{Sim}(w_i, t)$), sembari memberikan penalti pengurang dengan meminimalkan tingkat kemiripan kata tersebut terhadap himpunan kata kunci yang sudah terpilih sebelumnya ($(1 - \lambda) \max \text{Sim}(w_i, w_j)$). Nilai λ bertindak sebagai pengontrol; nilai yang mendekati 1 akan menghasilkan kata kunci yang sangat relevan namun berpotensi redundan, sedangkan nilai yang mendekati 0 akan menghasilkan

kata kunci yang sangat beragam namun berpotensi melenceng dari topik. Melalui mekanisme penyeimbangan ini, representasi akhir dari sebuah topik dipastikan akurat secara konteks semantik sekaligus memiliki variasi istilah yang representatif untuk interpretasi manusia.

2.12 *Dynamic Topic Modeling (DTM)*

Pemodelan topik konvensional, seperti LDA standar, bekerja dengan asumsi bahwa urutan dokumen dalam korpus tidak mempengaruhi hasil (*exchangeability*), sehingga model ini bersifat statis dan mengabaikan dimensi temporal. Akibatnya, metode ini tidak mampu menangkap dinamika perubahan topik, tren, atau pergeseran makna kata yang terjadi seiring berjalannya waktu. Untuk mengatasi keterbatasan ini, dikembangkan pendekatan *Dynamic Topic Modeling (DTM)* yang bertujuan memodelkan evolusi topik dalam data urutan waktu (*sequential data*).

Secara prinsip, DTM memperlakukan data sebagai aliran dokumen yang terbagi dalam irisan waktu (*time slices*). Model ini memungkinkan peneliti untuk mengamati dua fenomena utama yaitu perubahan prevalensi topik (popularitas topik naik/turun) dan evolusi konten topik (perubahan kata kunci representatif). Sebagai contoh, dalam korpus skripsi, topik "Jaringan Komputer" pada tahun 2010 mungkin didominasi kata kunci "LAN/WAN", namun berevolusi menjadi "IoT/5G" pada tahun 2024 (Blei & Lafferty, 2006).

Dalam kerangka kerja BERTopic, pendekatan DTM diterapkan dengan strategi yang berbeda dari model probabilistik tradisional yang menggunakan rantai Markov. BERTopic menggunakan pendekatan berbasis representasi topik global yang disesuaikan secara temporal. Algoritma ini pertama-tama melatih model pada seluruh dokumen untuk membentuk kluster topik global yang stabil, memastikan konsistensi identitas topik sepanjang waktu. Setelah itu, dokumen dipartisi berdasarkan *timestamp* (misalnya per tahun) dan representasi topik dihitung ulang secara lokal menggunakan variasi c-TF-IDF temporal. Rumus untuk bobot kata t pada topik c di waktu i didefinisikan pada persamaan (5) berikut:

$$c\text{-}TF\text{-}IDF_i = \frac{tf_{i,c}}{\sum_t tf_{i,c}} \times \log \left(1 + \frac{A}{f_i} \right) \quad (7)$$

(Grootendorst, 2022)

Pendekatan ini memungkinkan identifikasi tren yang muncul (*emerging*) atau menurun (*declining*) secara presisi tanpa merusak struktur dasar topik, memberikan wawasan yang lebih akurat mengenai evolusi riset akademik dari waktu ke waktu.

2.13 Evaluasi Kinerja Model

Evaluasi terhadap model pemodelan topik (*topic modeling*) merupakan tahapan krusial untuk memastikan bahwa topik yang dihasilkan memiliki kualitas semantik yang baik dan dapat diinterpretasikan. Mengingat penelitian ini menggunakan pendekatan unsupervised learning yang tidak memiliki label kebenaran mutlak (*ground truth*), evaluasi tidak dapat dilakukan menggunakan metrik akurasi atau precision konvensional. Oleh karena itu, penelitian ini menerapkan pendekatan evaluasi ganda (*dual-metric evaluation*) yang mencakup *Topic Coherence* untuk menilai kualitas internal topik (Nursyahrina dkk., 2024) dan *Topic Diversity* untuk menilai variasi eksternal antar topik. Kombinasi kedua metrik ini digunakan sebagai standar objektif untuk menentukan konfigurasi model terbaik yang mampu menghasilkan topik yang padu secara makna sekaligus beragam secara konten.

2.13.1 Topic Coherence

Prinsip dasar dari metrik C_v adalah mengukur tingkat korelasi semantik antara kata-kata representatif (biasanya 10 kata teratas) dalam suatu topik (Röder dkk., 2015). Sebuah topik dianggap koheren dan berkualitas tinggi apabila kata-kata penyusunnya memiliki keterkaitan yang kuat dan sering muncul bersamaan (*co-occurrence*) dalam korpus dokumen, sehingga membentuk satu kesatuan makna yang mudah dipahami (Aletras & Stevenson, 2013). Secara matematis, perhitungan C_v memanfaatkan nilai *Normalized Pointwise Mutual Information* (NPMI) dan kesamaan vektor kosinus pada jendela geser (*sliding window*) teks. Langkah pertama adalah

menghitung nilai NPMI untuk setiap pasangan kata (w_i, w_j) guna mengukur kekuatan asosiasinya, dengan rumus sebagai berikut:

$$\text{NPMI}(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}}{-\log P(w_i, w_j)} \quad (8)$$

(Röder dkk., 2015)

Dimana $P(w_i, w_j)$ adalah probabilitas kemunculan kedua kata secara bersamaan, sedangkan $P(w_i)$ dan $P(w_j)$ adalah probabilitas kemunculan masing-masing kata secara independen. Berbeda dengan metrik koherensi tradisional (seperti C_{UCI} atau C_{NPMI}) yang sekadar menjumlahkan skor perhitungan secara langsung, metrik C_v merepresentasikan kata ke dalam ruang vektor. Nilai-nilai NPMI dari setiap kata dipetakan menjadi sebuah vektor konteks $\vec{v}(w_i)$. Selanjutnya, tingkat koherensi dihitung dengan mengukur kedekatan jarak antar vektor kata tersebut terhadap representasi agregat vektor topik secara keseluruhan ($\vec{v}(W)$) menggunakan perhitungan kesamaan kosinus tidak langsung (*indirect cosine similarity*). Secara konseptual, perhitungan agregasi untuk skor akhir C_v pada sebuah himpunan kata representatif W dirumuskan pada persamaan (9) berikut:

$$C_v(W) = \frac{1}{|W|} \sum_{w_i \in W} \text{CosineSim}(\vec{v}(w_i), \vec{v}(W)) \quad (9)$$

Nilai akhir dari skor C_v ini direpresentasikan dalam rentang nilai 0 hingga 1. Perolehan nilai yang mendekati 1 mengindikasikan tingkat koherensi yang sangat tinggi, di mana kluster kata dalam topik tersebut memiliki konjungsi semantik yang sangat erat dan mudah diinterpretasikan. Rata-rata skor C_v ini akan dijadikan sebagai parameter objektif utama untuk mengomparasi dan memvalidasi keunggulan kinerja antara model *baseline* LDA dan model usulan BERTopic.

2.13.2 *Topic Diveristy*

Selain koherensi, kualitas model juga ditentukan oleh keragaman topik yang dihasilkan (*Topic Diversity*). Metrik ini berfungsi untuk mengukur seberapa unik topik-topik tersebut satu sama lain dan mendeteksi adanya redundansi, yaitu kondisi di mana model menghasilkan beberapa topik dengan kata kunci yang identik atau sangat mirip. Menurut Dieng dkk. (2020), *Topic Diversity* didefinisikan sebagai persentase kata-kata unik dalam sekumpulan kata-kata teratas (biasanya 25 kata teratas) dari seluruh topik yang terbentuk.

Secara formal, jika K adalah jumlah total topik dan V_k adalah himpunan kata-kata teratas dari topik ke- k , maka keragaman topik dihitung dengan persamaan (7):

$$Diversity = \frac{|\bigcup_{k=1}^K V_k|}{\sum_{k=1}^K |V_k|} \quad (10)$$

Nilai *Topic Diversity* berkisar antara 0 hingga 1. Nilai yang mendekati 1 menunjukkan bahwa topik-topik yang dihasilkan sangat beragam (heterogen) dan mencakup berbagai aspek pembahasan yang berbeda dalam korpus. Sebaliknya, nilai yang rendah mengindikasikan tingginya tumpang tindih (*overlap*) antar topik, yang berarti model gagal memisahkan konsep-konsep yang berbeda secara tegas.

2.14 Penelitian Sejenis

Penelitian ini berada di persimpangan tiga domain strategis dalam pengolahan teks: penerapan *Neural Topic Modeling* berbasis *embedding* Bahasa Indonesia, analisis dinamika evolusi topik temporal (*Dynamic Topic Analysis*), dan studi komparatif kinerja terhadap model probabilistik tradisional. Studi-studi sebelumnya cenderung berfokus pada salah satu dari domain ini secara terpisah, misalnya hanya menerapkan LDA untuk pemodelan statis atau menggunakan BERT untuk klasifikasi tanpa analisis topik mendalam. Tabel 2.3 menyajikan ringkasan dari beberapa penelitian relevan dan menyoroti

perbedaan metodologis utamanya dengan penelitian yang diusulkan ini, khususnya dalam aspek validasi kinerja terhadap model *baseline*.

Tabel 2. 3 Perbandingan Penelitian Terkait

No	Peneliti (Tahun)	Judul	Hasil	Perbedaan
1	(Riyantoni , 2024)	<i>Topic Modeling Skripsi Program Studi Sistem Informasi Menggunaka n Kombinasi BERTopic dan IndoSBERT</i>	Berhasil memetakan topik-topik statis pada skripsi akademik menggunakan BERTopic dengan visualisasi kompak dan terpisah	Penelitian ini melakukan analisis temporal (DTA) untuk melacak evolusi topik dari waktu ke waktu; Riyantoni hanya melakukan mapping statis tanpa analisis temporal dan tidak melakukan perbandingan dengan baseline LDA
2	(Nugraha & Nugraheni, 2024)	Topic Modeling Dokumen Skripsi Prodi Pendidikan Teknik Informatika dan Komputer Universitas	Berhasil memetakan topik-topik skripsi Indonesia menggunakan LDA; mengidentifik	Penelitian ini mengganti LDA dengan BERTopic- IndoBERT yang lebih modern dan mengintegrasika n Temporal Analysis;

		Negeri Jakarta Menggunakan Metode Latent Dirichlet Allocation	asi pola penelitian	Nugraha & Nugraheni menggunakan metode konvensional yang mengabaikan konteks semantik dan tidak melacak evolusi topik
3	(Diyasa, 2023)	Pemodelan Topik pada Tweet Berbahasa Indonesia Menggunakan BERTopic	Menerapkan BERTopic untuk analisis tweet dengan coherence score lebih tinggi dibanding LDA	Corpus berbeda (tweet media sosial singkat vs. abstrak skripsi akademik formal dan panjang); tidak ada perbandingan komparatif BERTopic vs. LDA; tidak ada temporal analysis
4	(Nugroho, 2023)	Analisis Komparatif Pemodelan Topik Metode Latent Dirichlet Allocation	Berhasil mengidentifik asi topik-topik dari artikel berita menggunakan BERTopic	Teks yang dianalisis informal dan pendek (artikel berita) vs. abstrak skripsi yang formal dan

		(LDA) dan BERTopic Pada Berita Berbahasa Indonesia		teknis; tidak ada aspek temporal dan tidak ada baseline comparison
5	(Wahyuni dkk., 2025)	<i>Implementati on of BERTopic for Topic Modeling Analysis of the Free Nutritious Meal Program Based on YouTube Comments</i>	Menganalisis opini publik terkait program pemerintah di YouTube menggunakan BERTopic dengan hasil koherensi yang baik.	Objek penelitian berupa komentar media sosial (bahasa tidak baku), sedangkan penelitian ini berfokus pada teks akademis formal (skripsi). Selain itu, penelitian tersebut tidak menerapkan <i>Dynamic Topic Modeling</i> (DTM).
6	(Hutama & Suhartono, 2022)	<i>Indonesian Hoax News Classification with Multilingual Transformer Model and BERTopic</i>	Melakukan komparasi performa antara BERTopic dan LDA dalam mengklasifikasi berita <i>hoax</i>	Fokus utama adalah klasifikasi berita (berlabel), sedangkan penelitian ini berfokus pada eksplorasi evolusi topik

			berbahasa Indonesia.	(<i>unsupervised</i>) dan menggunakan IndoBERT yang lebih spesifik dibandingkan model <i>Multilingual</i> yang digunakan pada studi tersebut.
7	Muhamad Galih (H1D022052)	Analisis Evolusi Topik Riset Skripsi Informatika Menggunakan <i>Neural Topic Modeling</i> (Bertopic) Berbasis Indobert untuk <i>Dynamic Topic Analysis</i>		Mengintegrasikan <i>embedding</i> IndoBERT (kontekstual), menerapkan analisis <i>time-series</i> (DTM), dan melakukan uji komparasi <i>head-to-head</i> melawan LDA. Menggunakan data dari repository Universitas Jenderal Soedirman

BAB III

METODOLOGI PENELITIAN

3.1 Waktu dan Tempat Penelitian

Penelitian akan dilakukan selama tiga bulan, terhitung dari bulan Januari 2026 hingga Maret 2026. Penelitian ini dilaksanakan di Fakultas Teknik Universitas Jenderal Soedirman dengan alamat Jl. Raya Mayjen Sungkono No.KM 5, Dusun 2, Blater, Kec. Kalimanah, Kabupaten Purbalingga, Jawa Tengah 53371.

3.2 Alat Penelitian

Dalam penelitian yang dilakukan, akan digunakan beberapa alat atau perangkat keras yang diperlukan, baik dalam bentuk perangkat keras atau perangkat lunak. Berikut adalah perangkat penelitian yang akan digunakan :

1. Perangkat Keras

Laptop Lenovo Ideapad Slim 3 14ACL6 dengan spesifikasi sebagai berikut :

- i. Prosesor : AMD Ryzen 3 seri 5300u
- ii. RAM : 8 GB DDR4
- iii. Penyimpanan : 512 GB
- iv. GPU : Radeon Graphics Vega 8

2. Perangkat Lunak


- i. Sistem Operasi Windows 10 Home
- ii. Bahasa Pemrograman Python
- iii. Framework Laravel
- iv. Visual Studio Code
- v. Google Colaboratory

vi. Microsoft Word

vii. Draw.io

3.3 Tahapan Penelitian

Untuk mencapai tujuan penelitian secara sistematis, tahapan pelaksanaan penelitian ini disusun mengikuti alur kerja yang divisualisasikan pada Gambar 3.1. Secara garis besar, tahapan ini terdiri dari pengumpulan data, pra-pemrosesan data (*preprocessing*) yang terbagi menjadi dua jalur spesifik, pembangunan model (*topic modeling*), evaluasi model, hingga analisis topik dinamis.



Gambar 3. 1 Diagram alur penelitian


3.3.1 Pengumpulan Data (*Data Collection*)

Penelitian diawali dengan tahap Pengumpulan Data. Dataset yang digunakan bersumber dari repositori digital Jurusan Informatika yang diakuisisi dalam format terstruktur. Data tersebut memuat empat atribut

metadata esensial, yaitu Judul, Abstrak, Kesimpulan, dan Tahun Publikasi. Dalam proses ini, diterapkan strategi penanganan data (*data handling*) untuk mengatasi kendala akses repositori, yaitu apabila teks Kesimpulan berstatus terbatas (*restricted*) atau tidak dapat diakses, maka atribut Kesimpulan tersebut akan diabaikan (tidak disubstitusi untuk mencegah duplikasi bobot kata). Seluruh atribut teks yang tersedia (Judul, Abstrak, dan Kesimpulan jika ada) kemudian digabungkan menjadi satu korpus teks utama (*concatenated text*) untuk memperkaya konteks semantik yang akan dipelajari oleh model, sedangkan atribut tahun publikasi difungsikan sebagai variabel waktu (*timestamp*) yang menjadi syarat mutlak untuk pelaksanaan analisis topik dinamis.

3.3.2 Arsitektur Pipeline Data (*Data Pipeline Architecture*)

Untuk memperjelas mekanisme transformasi data dari format mentah (*raw data*) hingga menjadi representasi topik yang valid, penelitian ini merancang arsitektur *pipeline* data yang memisahkan aliran informasi berdasarkan fungsinya. Berbeda dengan tahapan penelitian umum, arsitektur ini secara spesifik memvisualisasikan percabangan skenario pra-pemrosesan (*preprocessing*) yang disesuaikan dengan karakteristik model. Pada jalur model *baseline* (LDA), data teks diproses menggunakan teknik *Stemming* untuk menghasilkan token kata dasar, sedangkan pada jalur model usulan (BERTopic), struktur kalimat utuh dipertahankan tanpa *Stemming* guna mengoptimalkan pembacaan konteks oleh model *embedding*. Selain itu, arsitektur ini juga mempertegas alur integrasi metadata temporal (Tahun Publikasi) yang dipisahkan sejak awal dan tidak dilibatkan dalam pemrosesan teks, melainkan dialirkan langsung menuju tahap *Dynamic Topic Analysis*. Detail lengkap mengenai aliran data dan arsitektur sistem ini disajikan pada Gambar 3.2.



Gambar 3. 2. Arsitektur Pipeline Data dan Pemrosesan Model

3.3.3 Pra-pemrosesan Data (*Text Preprocessing*)

Memasuki tahap Pra-pemrosesan Data, penelitian ini menerapkan teknik pembersihan khusus mengingat data (terutama Kesimpulan hasil ekstraksi PDF) sering kali mengandung artefak yang tidak relevan. Proses ini dibagi menjadi dua pendekatan:

- a) **Pembersihan Artefak Dokumen:** Dilakukan pembersihan awal untuk menghapus gangguan teks akibat konversi format, seperti nomor halaman, header bab (misalnya teks "BAB V" atau "PENUTUP"), serta karakter *newline* berlebih yang memutus kalimat. Langkah ini krusial untuk menjaga keutuhan struktur kalimat pada data kesimpulan.
- b) **Percabangan Skenario *Preprocessing*:** Untuk jalur model *baseline* LDA, pra-pemrosesan dilanjutkan secara ketat meliputi normalisasi teks, penghapusan kata umum (*stopword removal*) menggunakan kamus standar bahasa Indonesia yang diperluas dengan istilah akademik, serta penerapan *stemming* untuk mereduksi variasi kata. Sebaliknya, pada jalur model usulan BERTopic, proses *stemming* maupun penghapusan kata hubung (*stopword removal*) ditiadakan pada tahap awal masukan. Hal ini bertujuan agar nuansa semantik (*semantic nuance*) dan struktur gramatikal dari kalimat yang utuh tetap terjaga, sehingga dapat dipahami secara optimal oleh model bahasa *embedding* (IndoSBERT). Penghapusan *stopword* pada model BERTopic baru akan dieksekusi secara spesifik pada fase akhir, tepat sebelum algoritma c-TF-IDF menghitung bobot representasi kata kunci. Strategi penundaan ini memastikan bahwa representasi vektor dokumen mampu menangkap konteks secara utuh, sementara representasi kata kunci topiknya pada luaran akhir tetap bersih dari kata-kata yang tidak bermakna..

3.3.4 Pembangunan Model Topik

Pada tahapan ini, dua arsitektur pemodelan topik dikembangkan dan dieksekusi secara komparatif. Sebagai model *baseline*, algoritma *Latent*

Dirichlet Allocation (LDA) dilatih menggunakan representasi fitur teks berbasis *Bag-of-Words* (BoW). Mengingat LDA mensyaratkan penentuan jumlah klaster secara apriori, diterapkan skema pencarian grid (*grid search*) guna menemukan parameter jumlah topik (K) yang paling optimal dalam rentang yang telah ditentukan. Evaluasi penentuan model LDA terbaik pada fase iterasi ini didasarkan secara objektif pada perolehan nilai metrik *Topic Coherence* (C_v) tertinggi, sehingga dapat dipastikan bahwa klaster kata yang dihasilkan memiliki tingkat keterkaitan semantik yang valid. Di sisi lain, model usulan utama yaitu BERTopic dibangun menggunakan pendekatan modular dengan konfigurasi arsitektur sebagai berikut:

- a) Representasi kalimat (*sentence-embedding*) pada abstrak skripsi diekstraksi menggunakan model IndoSBERT (denaya/indoSBERT-large). Model ini merupakan arsitektur IndoBERT berskala besar (*large*) yang telah dilatih secara khusus menggunakan pendekatan *Siamese Network* untuk tugas evaluasi kesamaan semantik. Penggunaan model ini memastikan bahwa vektor representasi dokumen berbahasa Indonesia yang dihasilkan memiliki tingkat akurasi pemahaman konteks yang tinggi untuk kebutuhan klasterisasi.
- b) Reduksi dimensi menggunakan algoritma UMAP.
- c) Klasterisasi berbasis densitas menggunakan HDBSCAN untuk menangkap struktur topik yang lebih natural.
- d) Representasi topik menggunakan variasi algoritma c-TF-IDF yang dioptimasi lebih lanjut dengan teknik *Maximal Marginal Relevance* (MMR). Pendekatan ini bertujuan untuk menyeleksi representasi kata kunci yang paling relevan dengan inti topik, sekaligus meminimalkan redundansi semantik antar kata kunci yang terpilih.

3.3.5 Evaluasi dan Seleksi Model

Kualitas topik yang dihasilkan dievaluasi secara kuantitatif menggunakan metrik *Coherence Score* (C_v) untuk mengukur tingkat keterkaitan semantik antar kata kunci, serta *Topic Diversity* untuk mengukur

variasi topik. Model dengan skor koherensi tertinggi ditetapkan sebagai model terbaik (Best Model).

Pemilihan *Coherence Score* (C_v) sebagai metrik evaluasi utama didasarkan pada karakteristik penelitian pemodelan topik yang bersifat *unsupervised learning*, di mana tidak tersedia label kebenaran (*ground truth*) untuk menghitung akurasi. Berbeda dengan metrik statistik tradisional seperti Perplexity yang sering kali tidak berkorelasi dengan pemahaman manusia (*human interpretability*), Coherence Score mengukur tingkat kesamaan semantik antar kata-kata teratas dalam sebuah topik.

Nilai C_v yang tinggi mengindikasikan bahwa kata-kata dalam satu topik memiliki keterkaitan makna yang kuat dan logis, sehingga topik tersebut lebih mudah diinterpretasikan. Selain itu, metrik ini berfungsi sebagai standar objektif untuk mengkomparasi kinerja dua algoritma dengan arsitektur berbeda yaitu LDA yang berbasis statistik dan BERTopic yang berbasis embedding secara adil (*apple-to-apple*) berdasarkan kualitas topik yang dihasilkan.

3.3.6 Analisis Dinamika Topik (*Dynamic Topic Analysis*)

Model terpilih digunakan untuk menjalankan analisis *Topics over Time*. Algoritma ini memetakan evolusi topik dengan menghitung ulang bobot representasi c-TF-IDF pada setiap irisan waktu berdasarkan metadata tahun skripsi. Hasil analisis ini divisualisasikan untuk mengidentifikasi pola tren riset, baik yang bersifat *emerging* (naik), *declining* (turun), maupun stabil sepanjang periode pengamatan.

3.3.7 Visualisasi dan Interpretasi Hasil

Tahap akhir penelitian difokuskan pada penyajian hasil analisis melalui pengembangan dasbor interaktif (*interactive dashboard*) berbasis web menggunakan kerangka kerja Laravel. Pendekatan ini dipilih untuk memfasilitasi eksplorasi data secara dinamis dan terstruktur, memungkinkan pengguna untuk memfilter serta memantau tren topik secara real-time dengan fleksibilitas yang lebih tinggi dibandingkan visualisasi statis konvensional. Melalui integrasi antara *backend* Laravel dan pustaka

visualisasi antarmuka pengguna, sistem ini menyajikan pemetaan karakteristik topik secara komprehensif yang mencakup distribusi global maupun dinamika temporal.

Secara teknis, visualisasi struktur topik diimplementasikan melalui grafik batang (*Bar Chart*) interaktif yang memetakan distribusi jumlah dokumen untuk mengidentifikasi topik dominan dalam korpus riset. Untuk memperdalam interpretasi semantik, sistem juga menampilkan visualisasi Awan Kata (*Word Clouds*) dan grafik batang skor c-TF-IDF yang merepresentasikan bobot kata terpenting dalam setiap kluster, sehingga mempermudah validasi label topik yang terbentuk.

Selanjutnya, analisis aspek temporal difasilitasi melalui Grafik Evolusi Tren (*Dynamic Trend Graph*) yang memetakan kurva popularitas topik sepanjang rentang waktu penelitian (2019–2025). Grafik garis ini merepresentasikan perubahan frekuensi atau probabilitas topik di setiap irisan waktu (*time slice*), yang digunakan sebagai dasar untuk mengkategorikan topik ke dalam tiga status tren utama: *Emerging Topics* untuk topik dengan tren kenaikan signifikan, *Declining Topics* untuk topik yang mulai jenuh, dan *Stable Topics* untuk topik dengan konsistensi frekuensi. Hasil visualisasi pada dasbor Laravel ini kemudian diinterpretasikan secara kualitatif untuk menarik kesimpulan strategis mengenai peta perkembangan riset di lingkungan Jurusan Informatika Universitas Jenderal Soedirman.

3.4 Jadwal Penelitian

Penelitian ini dilaksanakan secara mandiri bertempat di lingkungan Fakultas Teknik, Universitas Jenderal Soedirman. Seluruh rangkaian kegiatan, mulai dari akuisisi data hingga analisis hasil, direncanakan berlangsung selama periode tiga bulan efektif, terhitung mulai bulan Januari 2026 hingga Maret 2026. Alokasi waktu ini disusun secara bertahap guna memastikan setiap fase metodologi terutama pemrosesan dual-pipeline dan analisis tren dinamis dapat terlaksana dengan optimal. Rincian jadwal kegiatan disajikan dalam bentuk Gantt Chart pada Tabel 3.1.

Tabel 3. 1 Jadwal Penelitian

No	Kegiatan Penelitian	Januari	Februari	Maret
1	Persiapan & Manajemen Data			
	a. Studi Literatur			
	b. Akuisisi Data (Scraping Repositori)			
	c. Validasi & Substitusi Data			
2	Implementasi Pipa Komputasi (Coding)			
	a. Pra-pemrosesan Data (Dual-Pipeline)			
	b. Pembangunan Model LDA			
	c. Pembangunan BERTopic			
3	Evaluasi & Analisis Model			
	a. Komparasi Metrik			
	b. Analisis Dinamika Tren			
	c. Interpretasi Visualisasi			

4	Penyusunan Laporan			
	a. Penyusunan Naskah & Pembahasan			
	b. Finalisasi Laporan Skripsi			

DAFTAR PUSTAKA

- Aletras, N., & Stevenson, M. (2013). Evaluating Topic Coherence Using Distributional Semantics. *International Conference on Computational Semantics*. <https://api.semanticscholar.org/CorpusID:15651747>
- Blei, D. M., & Lafferty, J. D. (2006). Dynamic topic models. *Proceedings of the 23rd international conference on Machine learning - ICML '06*, 113–120. <https://doi.org/10.1145/1143844.1143859>
- Blei, D. M., Ng, A. Y., & Edu, J. B. (2003). Latent Dirichlet Allocation Michael I. Jordan. Dalam *Journal of Machine Learning Research* (Vol. 3).
- Campello, R. J. G. B., Moulavi, D., & Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates* (hlm. 160–172). https://doi.org/10.1007/978-3-642-37456-2_14
- Carbonell, J., & Goldstein, J. (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. *Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval*, 335–336. <https://doi.org/10.1145/290941.291025>
- Cheddak, A., Ait Baha, T., Es-Saady, Y., El Hajji, M., & Baslam, M. (2024). BERTopic for Enhanced Idea Management and Topic Generation in Brainstorming Sessions. *Information*, 15(6), 365. <https://doi.org/10.3390/info15060365>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North*, 4171–4186. <https://doi.org/10.18653/v1/N19-1423>
- Diyasa, F. G. (2023). *PEMODELAN TOPIK PADA TWEET BAHASA INDONESIA MENGGUNAKAN BERTOPIC*. Universitas Sriwijaya.
- Dogra, V., Verma, S., Kavita, Chatterjee, P., Shafi, J., Choi, J., & Ijaz, M. F. (2022). A Complete Process of Text Classification System Using State-of-the-Art NLP Models. *Computational Intelligence and Neuroscience*, 2022, 1–26. <https://doi.org/10.1155/2022/1883698>
- Edward Jones, D. (t.t.). *IMPROVING ENGINEERING INFORMATION RETRIEVAL BY COMBINING TD-IDF AND PRODUCT STRUCTURE CLASSIFICATION* (Vol. 6). Design Information and Knowledge.
- Egger, R., & Yu, J. (2022). A Topic Modeling Comparison Between LDA, NMF, Top2Vec, and BERTopic to Demystify Twitter Posts. *Frontiers in Sociology*, 7. <https://doi.org/10.3389/fsoc.2022.886498>

- Faizah, S., Zaenudin, M., & Nugraha, D. (2023). WORKSHOP PENYUSUNAN SKRIPSI, PUBLIKASI ILMIAH DAN PEMBUATAN POSTER ILMIAH BAGI MAHASISWA TINGKAT AKHIR JAKARTA GLOBAL UNIVERSITY. *Jurnal Abdi Insani*, 10(3), 1543–1554.
<https://doi.org/10.29303/abdiinsani.v10i3.1064>
- Fajari, R., Saputra, B., Berlinson, A. M., Parhusip, J., Palangkaraya, U., Yos, J., Palangka, S., Jekan, K., Kota, R., & Raya, P. (2024). Pengembangan Kurikulum Berbasis Informatika untuk Memenuhi Kebutuhan Industri di Era Digital Curriculum Development to Meet Industry Needs in the Digital Era. *Jurnal Ilmiah Informatika dan Komputer*, 1(2), 205–210.
- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv preprint arXiv:2203.05794*.
<http://arxiv.org/abs/2203.05794>
- Hutama, L. B., & Suhartono, D. (2022). Indonesian Hoax News Classification with Multilingual Transformer Model and BERTopic. *Informatica*, 46(8).
<https://doi.org/10.31449/inf.v46i8.4336>
- Jelodar, H., Wang, Y., Yuan, C., Feng, X., Jiang, X., Li, Y., & Zhao, L. (2019). Latent Dirichlet allocation (LDA) and topic modeling: models, applications, a survey. *Multimedia Tools and Applications*, 78(11), 15169–15211.
<https://doi.org/10.1007/s11042-018-6894-4>
- Khairunnisa, S., Adiwijaya, A., & Faraby, S. Al. (2021). Pengaruh Text Preprocessing terhadap Analisis Sentimen Komentar Masyarakat pada Media Sosial Twitter (Studi Kasus Pandemi COVID-19). *JURNAL MEDIA INFORMATIKA BUDIDARMA*, 5(2), 406.
<https://doi.org/10.30865/mib.v5i2.2835>
- Khurana, D., Koli, A., Khatte, K., & Singh, S. (2023). Natural language processing: state of the art, current trends and challenges. *Multimedia Tools and Applications*, 82(3), 3713–3744. <https://doi.org/10.1007/s11042-022-13428-4>
- Liu, Y. (2024). Comparison of LDA and BERTopic in News Topic Modeling: A Case Study of The New York Times' Reports on China. *Pacific International Journal*, 7, 47–51. <https://doi.org/10.55014/pij.v7i3.616>
- Ma, L., Chen, R., Ge, W., Rogers, P., Lyn-Cook, B., Hong, H., Tong, W., Wu, N., & Zou, W. (2025). AI-powered topic modeling: comparing LDA and BERTopic in analyzing opioid-related cardiovascular risks in women. *Experimental Biology and Medicine*, 250.
<https://doi.org/10.3389/ebm.2025.10389>
- McInnes, L., Healy, J., & Melville, J. (2020). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*.
<http://arxiv.org/abs/1802.03426>

- Nafi', A., Harjanta, A. T., Herlambang, B. A., & Fahmi, S. (2024). Analisis Sentimen Review Pelanggan Lazada dengan Sastrawi Stemmer dan SVM-PSO untuk Memahami Respon Pengguna. *J-INTECH*, 12(02), 330–339. <https://doi.org/10.32664/j-intech.v12i02.1450>
- Natasya Priyani, Nadya Revelin Putri, Atong Nazarius, & Jadianan Parhusip. (2024). TRANSFORMASI KURIKULUM PENDIDIKAN UNTUK MENINGKATKAN KOMPETENSI TEKNOLOGI DALAM ERA DIGITAL. *Informatika: Jurnal Teknik Informatika dan Multimedia*, 4(2), 08–12. <https://doi.org/10.51903/informatika.v4i2.824>
- Nugraha, E., & Nugraheni, M. (2024). TOPIC MODELING DOKUMEN SKRIPSI PRODI PENDIDIKAN TEKNIK INFORMATIKA DAN KOMPUTER UNIVERSITAS NEGERI JAKARTA MENGGUNAKAN METODE LATENT DIRICHLET ALLOCATION. *PINTER: Jurnal Pendidikan Teknik Informatika dan Komputer*, 8(2), 21–30.
- Nugroho, A. D. Y. (2023). ANALISIS KOMPARASI PEMODELAN TOPIK METODE LATENT DIRICHLET ALLOCATION (LDA) DAN BERTOPIC PADA BERITA BERBAHASA INDONESIA. Universitas Islam Negeri Sunan Kalijaga Yogyakarta.
- Nursyahrina, Defit, S., & Sovia, R. (2024). Metode BERTopic dan LDA untuk Analisis Tren Penelitian Bidang Ilmu Komputer. *Jurnal KomtekInfo*, 332–341. <https://doi.org/10.35134/komtekinfo.v11i4.580>
- Otter, D. W., Medina, J. R., & Kalita, J. K. (2021). A Survey of the Usages of Deep Learning for Natural Language Processing. *IEEE Transactions on Neural Networks and Learning Systems*, 32(2), 604–624. <https://doi.org/10.1109/TNNLS.2020.2979670>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3980–3990. <https://doi.org/10.18653/v1/D19-1410>
- Riyantoni, N. H. (2024). TOPIC MODELING SKRIPSI PROGRAM STUDI SISTEM INFORMASI MENGGUNAKAN KOMBINASI BERTOPIC DAN INDOSBERT. UNIVERSITAS ISLAM NEGERI SUNAN AMPEL SURABAYA.
- Rizki Yuni Lestari. (2025). PEMETAAN POLA PENELITIAN SKRIPSI BIDANG ILMU PERPUSTAKAAN DAN INFORMASI PADA PERGURUAN TINGGI NEGERI DI JAWA TIMUR: SEBUAH ANALISIS BIBLIOMETRIK. Univesitas Islam Negeri Malik Ibrahim Malang.

- Rizquina, A. Z., & Ratnasari, C. I. (2023). Implementasi Web Scraping untuk Pengambilan Data Pada Website E-Commerce. *Jurnal Teknologi Dan Sistem Informasi Bisnis*, 5(4), 377–383. <https://doi.org/10.47233/jteksis.v5i4.913>
- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the Space of Topic Coherence Measures. *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining*, 399–408. <https://doi.org/10.1145/2684822.2685324>
- Shalima, I., & Wijayanti, A. (2020). KESALAHAN BERBAHASA DALAM SKRIPSI MAHASISWA PRODI PENDIDIKAN BAHASA DAN SASTRA INDONESIA UNIVERSITAS TIDAR. *Indonesian Journal of Education and Learning*, 3(2). <https://doi.org/10.31002/ijel.v3i2.3244>
- Shi, H. (2024). Natural Language Processing and Text Mining Algorithms for Financial Accounting Information Disclosure. *Journal of Electrical System*.
- SPARCK JONES, K. (1972). A STATISTICAL INTERPRETATION OF TERM SPECIFICITY AND ITS APPLICATION IN RETRIEVAL. *Journal of Documentation*, 28(1), 11–21. <https://doi.org/10.1108/eb026526>
- Sultan, N. A., & Abdullah, D. B. (2022). Scraping Google Scholar Data Using Cloud Computing Techniques. *2022 8th International Conference on Contemporary Information Technology and Mathematics (ICCITM)*, 14–19. <https://doi.org/10.1109/ICCITM56309.2022.10032044>
- Susetyo, S., & Noermanzah, N. (2020). Kemampuan dan Kesulitan Mahasiswa Program Studi Pendidikan Bahasa Indonesia Universitas Bengkulu dalam Menulis Proposal Penelitian Skripsi. *Silampari Bisa: Jurnal Penelitian Pendidikan Bahasa Indonesia, Daerah, dan Asing*, 3(2), 182–201. <https://doi.org/10.31540/silamparibisa.v3i2.1071>
- Syahputra, J., & Rikki, A. (2021). Penerapan Metode Analytical Hierarchy Process (AHP) dalam Menentukan Judul Skripsi. *JUKI : Jurnal Komputer dan Informatika*, 2(2), 111–119. <https://doi.org/10.53842/juki.v2i2.34>
- Ulfah, A., & Najiah, I. (2023). IMPLEMENTASI WEB SCRAPING PADA SITUS JURNAL SINTA MENGGUNAKAN FRAMEWORK SELENIUM WEBDRIVER PYTHON. *JIKA (Jurnal Informatika)*, 7(1), 29. <https://doi.org/10.31000/jika.v7i1.7037>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2023). *Attention Is All You Need*. <http://arxiv.org/abs/1706.03762>
- Vayansky, I., & Kumar, S. A. P. (2020). A review of topic modeling methods. *Information Systems*, 94, 101582. <https://doi.org/10.1016/j.is.2020.101582>
- Wahyuni, W., Lestari, T. P., Apriliana, M., & Gumelta, R. (2025). Implementation of BERTopic for Topic Modeling Analysis of the Free Nutritious Meal

Program Based on YouTube Comments. *Journal of Applied Informatics and Computing*, 9(4), 1964–1971. <https://doi.org/10.30871/jaic.v9i4.9754>

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and Resources for Evaluating Indonesian Natural Language Understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, 843–857. <https://doi.org/10.18653/v1/2020.aacl-main.85>